

TRABAJO FIN DE MÁSTER · MÁSTER EN DESARROLLO DE SOFTWARE

Generación automática de informes clínicos a partir de dictados médicos

AUTOR

Eduardo Enrique Suárez Castro

DIRECTOR

Francisco Javier Melero Rus

Escuela Internacional de Posgrado · Universidad de Granada · Julio 2026

La documentación clínica consume el tiempo que debería dedicarse al paciente

25–40%

**del tiempo clínico se destina
a redactar informes**

Contribuye al agotamiento
profesional y reduce la atención
directa

El dictado de voz es habitual

Ampliamente adoptado en la práctica clínica diaria

Depende de transcripción manual y edición posterior

Un proceso lento, propenso a errores y que retrasa el informe final

Flujo ineficiente y no genera datos estructurados

El texto libre resultante no es interoperable ni reutilizable

Fuente: Clynych & Kellett, *Int. J. Med. Inform.* (2015) — "Documentation now occupies a quarter to half of doctors' time"

Objetivo general y objetivos específicos

OBJETIVO GENERAL

Diseñar, desarrollar y evaluar un sistema orientado a la **generación automatizada de informes clínicos estructurados** a partir de dictados de voz médicos. Y cumplimiento estricto de las normativas vigentes de **privacidad de datos de salud**.

O1 · Transcripción

$WER \leq 10-12\%$

Tasa de error de palabra en la transcripción del habla médica

O2 · Extracción de entidades

$F1 \geq 0.85$

Identificación y normalización de conceptos clínicos

O3 · Calidad clínica

$\geq 80\%$ aceptación

Informes valorados como clínicamente aceptables por especialistas

O4 · Interoperabilidad

$> 95\%$ validación

Salidas conformes al estándar FHIR sin errores de esquema

Del dictado al informe estructurado en cinco etapas



A partir de aquí, seguiremos un caso real...

Terminologías e interoperabilidad como base del sistema

SNOMED CT

Terminología clínica de referencia

Identifica y codifica con precisión semántica los conceptos médicos extraídos del dictado

CIE-10-ES

Clasificación diagnóstica oficial

Traduce los conceptos *SNOMED CT* a códigos diagnósticos usados en la práctica clínica española

HL7 FHIR

Estándar de interoperabilidad

Estructura el informe final para su intercambio con sistemas de Historia Clínica Electrónica

Los tres estándares actúan de forma encadenada: *SNOMED CT* identifica el concepto, *CIE-10-ES* lo clasifica y *HL7 FHIR* lo transporta.

Modelo cliente–gateway–servicio en tres capas desacopladas

Capa cliente


App móvil captura audio PCM (16 kHz, mono) y lo transmite por *WebSocket*

Capa de acceso

El *gateway* traduce *WebSocket* a peticiones HTTP y acumula el estado de la sesión

Capa de procesamiento

Servicio *FastAPI* ejecuta *ASR*, *PLN*, normalización y generación de informes



06 · CASO CLÍNICO



Mujer de 53 años de edad diagnosticada de hernia discal, en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años, con buena eficacia y seguridad.

Se cambia por fentanilo genérico y se nota un empeoramiento del cuadro doloroso. Se vuelve a cambiar a Durogesic, y de nuevo se estabiliza la analgesia.

La app transmite el audio en tiempo real por *WebSocket* seguro

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación



En espera

Grabando

Conexión *WSS* de extremo a extremo

Cifrada desde el primer fragmento de audio

Audio *PCM* en bloques de ~250 ms

Procesamiento incremental sin esperar al final

Estado visible en tiempo real

Conexión, nivel de voz y fragmentos emitidos

El **ASR** transcribe el dictado el audio que le llega por el *WebSocket*

1 · Captura

2 · **ASR**

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

DICTADO ORIGINAL

Mujer de 53 años de edad diagnosticada de hernia discal en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años

ASR →

TRANSCRIPCIÓN ASR

Mujer de 53 años de edad diagnosticada de hernia discal en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años

≈ **6.5%**

Tasa de error de palabra
(WER)

93.6%

Palabras transcritas
correctamente

≤ **10–12%**

Umbral objetivo definido
(O1)

El *NER* identifica y clasifica las entidades clínicas del texto transcrito

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

ENTIDAD RECONOCIDA

hernia discal**PROBLEM**

confianza 78 %

PATRONES DE ERROR MÁS COMUNES

Segmentación — divide conceptos de varias palabras**Siglas** — sin expandir ni normalizar**Términos genéricos** — se confunden con hallazgos**57.1 %**

Precisión

66.7 %

Recall

0.61F1-score · objetivo 02
 ≥ 0.85 no alcanzado

Filtrado y fusión de entidades contiguas para evitar la sobre-segmentación



Dos entidades *NER* contiguas del mismo modelo de origen (`pln_source`) se fusionan en una sola: la entidad resultante hereda la etiqueta del fragmento con mayor confianza y una puntuación promediada, evitando que un concepto de varias palabras se registre como entidades sueltas.

Normalización: mapeo de entidades a *SNOMED CT* y *CIE-10-ES*

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

TÉRMINO	SNOMED CT	CIE-10-ES
hernia discal	84857004	- (no aplica)
fentanilo	373492002	T40.4 / X42 / X62 / Y12 / Y45.0
doloroso	31681005 Valor incorrecto	R20.0

Durogesic, 50 µg/h y cuadro doloroso no tienen código clínico esperado (marca comercial, dosis y síntoma inespecífico) y quedan fuera del cálculo de aciertos.

60 %

Aciertos *SNOMED CT*
(3/5)

40 %

Aciertos *CIE-10-ES* (2/5)

1.25 s

Tiempo de normalización
del caso

El informe *LLM*: acierta el relato, arrastra errores previos

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

INFORME

Mujer de 53 años, **hernia discal**:
Durogesic → fentanilo genérico
(empeora) → vuelve a Durogesic
(mejora).

Impresión diagnóstica

Hernia Discal a estudio

OBSERVACIONES DE LA AUDITORÍA

ASR: casi perfecto (duplica "*Durogesic*
Durogesic").

NER: "*analgesia*" = falso positivo (PROBLEM).

SNOMED: "*doloroso*" → *Trigeminal neuralgia*
(CIE-10 err.).

Informe: dosis $\times 1000$ ("*50 μ g/h*" →
"*50 mg/hora*").

2 / 5

Puntuación del informe
LLM (Test 1)

30 %

Aceptación clínica · O3
 $\geq 80\%$ no alcanzado

34.1 s

Tiempo total del caso

El *Bundle FHIR* del caso: válido en forma, no en contenido

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

VALIDACIÓN ESTRUCTURAL

Bundle válido (4 / 5)

El *Bundle* de este caso supera la validación estructural: `resourceType`, referencias `subject` y `meta.profile` correctos.

Es, junto a *ASR* y *NER*, la dimensión mejor puntuada del caso —muy por encima de *Terminología* e *Informe* (2 / 5 ambas).

ADVERTENCIA SEMÁNTICA

La validación **no filtra** el contenido: el *Bundle* traslada, sin corregirlos, los errores ya vistos en este mismo caso.

NER: "*analgesia*" persiste como *Condition* (falso positivo).

Terminología: "*doloroso*" → *Trigeminal neuralgia* codificado como hallazgo (CIE-10 err.).

Informe: dosis $\times 1000$ ("*50 mg/hora*") pasa intacta al *MedicationStatement*.

4 / 5

Puntuación *FHIR* de este caso (*streaming* Test 1)

3

Persisten como hallazgos clínicos válidos

100 %

Objetivo 4 solo en forma

Evaluación por módulos y de extremo a extremo

10

casos de
referencia

Muestreo aleatorio de *SPACCC* (1.000 casos); *gold standard* anotado con *Claude Opus 4.5*.

**Evaluación
por módulos**

ASR · *NER* ·
Terminología

Cada etapa, aislada, frente a su propio *gold standard* (*WER*, precisión, *recall*, *F1*).

LLM-as-judge

Evaluación
end-to-end

Puntúa 1–5 en 5 dimensiones y emite veredicto de aceptación clínica (*proxy* del Objetivo 3).

2

modalidades:
batch y
streaming

Mismo motor *ASR*; cambia cómo el *gateway* agrupa el audio.


Los tres artefactos de salida (*Reporte.txt*, *Informe.txt*, *Fhir_Reporte.json*) se contrastan contra el texto de referencia de cada caso, en local y sin *GPU* de servidor.

14 · RESULTADOS *END-TO-END*

16 / 22

***Streaming* puntúa más en las 5 dimensiones, pero cuesta $\approx 6\times$ más tiempo**

● *Streaming*
● *Batch*



5 / 5

Dimensiones donde
streaming supera a *batch*

$\approx 6\times$

Más tiempo: 184.9 s vs
30.6 s de media

FHIR

Dimensión mejor puntuada
en ambos modos

NER: el *span* granular solo explica el 37 % del hueco

MÉTRICA (MICRO)	ESTRICTA	GRANULAR	Δ
Precisión	24.8 %	37.3 %	+12.4 pp
Recall	44.9 %	53.1 %	+8.2 pp
F1	32.0 %	43.8 %	+11.8 pp
Verdaderos positivos (TP)	40	60	+20
Falsos positivos (FP)	121	101	-20
Falsos negativos (FN)	49	53	+4

Sobre-segmentación: detecta fragmentos cortos dentro de una entidad más larga ("*doloroso*" en vez de "*cuadro doloroso*"), penalizando dos veces el mismo error.

Siglas no reconocidas: SDRC, HCA, DLE, AOC/DG, RMN. **Falsos positivos genéricos:** "*exploración física*", "*dolor*", "*lesión*".

37 % granularidad

63 % límite del modelo

Reparto estimado de la brecha de *F1* entre ambos criterios.

15 · HALLAZGO CENTRAL

Los errores no se diluyen en el *pipeline*: se acumulan

MÓDULO	EVALUACIÓN AISLADA		END-TO-END (1–5)
ASR	≈6.5 % (WER)	→	3.75–4.0 / 5
NER	32.0–43.8 % (F1)	→	2.10–2.90 / 5
Terminología	85.5 % (SNOMED)	→	1.55–1.90 / 5

Cada etapa consume la salida de la anterior sin posibilidad de corrección aguas abajo: un error moderado en origen (una sigla mal transcrita, una entidad truncada) se compone con el siguiente y se amplifica hasta convertirse en un error clínico grave en el informe final.

20–30 %

de los informes completos
resultan aceptables
(*LLM-as-judge*)

Cumplimiento dispar entre objetivos técnicos y clínicos

	OBJETIVO 1 · ASR $WER \leq 10-12\%$	RESULTADO $\approx 6.5\%$ medio	Consistente en ambas modalidades y los 10 casos; rango bajo ($\approx 0.6-13.6\%$).
	OBJETIVO 2 · NER $F1 \geq 0.85$	RESULTADO $32.0-43.8\%$	Muy por debajo del umbral: sobre-segmentación de <i>spans</i> y siglas/abreviaturas no reconocidas.
	OBJETIVO 3 · CLÍNICA $\geq 80\%$ aceptación	RESULTADO $20\% \cdot 30\%$	Propagación y amplificación de errores entre etapas del <i>pipeline</i> secuencial.
	OBJETIVO 4 · FHIR $FHIR > 95\%$ válido	RESULTADO 100%	Válido no es lo mismo que correcto: hereda sin filtrar los errores semánticos previos.

■ Cumplido ■ Cumplido con reservas ■ No cumplido

17 · CONCLUSIONES



El desempeño de un sistema clínico de este tipo no puede inferirse a partir del desempeño aislado de sus componentes.

Conclusiones generales · Capítulo 7

1

Arquitectura completa y funcional

Cubre de extremo a extremo el flujo del audio al recurso *FHIR*. Cumple el Objetivo 1 (*WER*) y el Objetivo 4 con reservas.

2

El problema es la propagación, no los módulos

Errores moderados y aislados se amplifican al encadenarse sin corrección. Los Objetivos 2 y 3 no se cumplen por esta causa.

3

Prueba de concepto, no producto clínico

Técnicamente viable, pero sin el nivel de fiabilidad necesario para operar sin supervisión clínica humana.

Líneas de continuación tras las limitaciones detectadas

1

Verificación entre etapas

Validar entidades *NER* contra el texto fuente y confirmar negaciones antes de normalizar.

2

Mejora del *NER*

Diccionario de siglas y abreviaturas clínicas; mejor delimitación de *spans* compuestos para reducir la sobre-segmentación.

3

Normalización con contexto

Entity linking sobre el dictado completo, no por coincidencia aislada; mejoraría la baja cobertura de *CIE-10-ES*.

4

Menos alucinaciones del *LLM*

RAG o verificación *post-generación* que contraste cada afirmación contra las entidades y el texto fuente.

Además, evaluar el *pipeline* sobre *hardware* con mayor *VRAM* permitiría usar *LLMs* de mayor escala que llama3.1:8b y aislar si las limitaciones observadas dependen del tamaño del modelo o de la arquitectura secuencial.

19 · CIERRE

Gracias

Preguntas y discusión

AUTOR

Eduardo Enrique Suárez Castro

eduardosuarez.c97@gmail.com

DIRECTOR

Francisco Javier Melero Rus