

TRABAJO FIN DE MÁSTER · MÁSTER EN DESARROLLO DE SOFTWARE

Generación automática de informes clínicos a partir de dictados médicos

AUTOR

Eduardo Enrique Suárez Castro

DIRECTOR

Francisco Javier Melero Rus

Escuela Internacional de Posgrado · Universidad de Granada · Julio 2026

La documentación clínica consume el tiempo que debería dedicarse al paciente

25–40%

**del tiempo clínico se destina
a redactar informes**

Contribuye al agotamiento
profesional y reduce la atención
directa

El dictado de voz es habitual

Ampliamente adoptado en la práctica clínica diaria

Depende de transcripción manual y edición posterior

Un proceso lento, propenso a errores y que retrasa el informe final

Flujo ineficiente y no genera datos estructurados

El texto libre resultante no es interoperable ni reutilizable

Fuente: Clynych & Kellett, *Int. J. Med. Inform.* (2015) — *"Documentation now occupies a quarter to half of doctors' time"*

Objetivo general y objetivos específicos

OBJETIVO GENERAL

Diseñar, desarrollar y evaluar un sistema orientado a la **generación automatizada de informes clínicos estructurados** a partir de dictados de voz médicos. Y cumplimiento estricto de las normativas vigentes de **privacidad de datos de salud** (LOPDGDD).

O1 · Transcripción

$WER \leq 10-12\%$

Tasa de error de palabra en la transcripción del habla médica

O2 · Extracción de entidades

$F1 \geq 0.85$

Identificación y normalización de conceptos clínicos

O3 · Calidad clínica

$\geq 80\%$ aceptación

Informes valorados como clínicamente aceptables por especialistas

O4 · Interoperabilidad

$> 95\%$ validación

Salidas conformes al estándar FHIR sin errores de esquema

Del dictado al informe estructurado en cinco etapas



A partir de aquí, seguiremos un caso real...

06 · CASO CLÍNICO



Mujer de 53 años de edad diagnosticada de hernia discal, en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años, con buena eficacia y seguridad.

Se cambia por fentanilo genérico y se nota un empeoramiento del cuadro doloroso. Se vuelve a cambiar a Durogesic, y de nuevo se estabiliza la analgesia.

La app transmite el audio en tiempo real por *WebSocket* seguro

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

Micrófono

Archivo

En espera

Desconectado

Permiso de micrófono concedido

Silencio

Nivel de voz: 0%

Duración de sesión

0:00s

Fragmentos emitidos

0

Último fragmento

0ms

Micrófono

Archivo

Grabando

Conectado

Permiso de micrófono concedido

Escuchando...

Nivel de voz: 7%

Duración de sesión

0:05s

Fragmentos emitidos

0

Último fragmento

0ms

En espera

Grabando

Conexión *WSS* de extremo a extremo

Cifrada desde el primer fragmento de audio

Audio *PCM* a 16kHz y 16 bits

Procesamiento incremental sin esperar al final

Estado visible en tiempo real

Conexión, nivel de voz y fragmentos emitidos

El **ASR** transcribe el dictado el audio que le llega por el **WebSocket**

1 · Captura

2 · **ASR**

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

DICTADO ORIGINAL

Mujer de 53 años de edad diagnosticada de hernia discal en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años

ASR →

TRANSCRIPCIÓN ASR

Mujer de 53 años de edad diagnosticada de hernia discal en tratamiento con Durogesic 50 $\mu\text{g}/\text{h}$ durante seis años

ERRORES OBSERVADOS EN EL ASR

- Siglas y epónimos clínicos cortos p. ej. "TTG"
- Confusiones fonéticas entre siglas similares, p. ej. "TTG" → "CTG"
- Errores ortográficos menores sobre vocabulario común (p. ej. "eficiencia" por "eficacia").

El *NER* identifica y clasifica las entidades clínicas del texto transcrito

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

ENTIDAD RECONOCIDA

hernia discal

PROBLEM

confianza 78 %

PATRONES DE ERROR MÁS COMUNES

Segmentación — divide conceptos de varias palabras

Siglas — sin expandir ni normalizar

Términos genéricos — se confunden con hallazgos

Para mitigar la **segmentación**, se aplicó un filtrado y fusión de entidades contiguas

Filtrado y fusión de entidades contiguas para evitar la sobre-segmentación



Dos entidades *NER* contiguas del mismo modelo de origen (`pln_source`) se fusionan en una sola: la entidad resultante hereda la etiqueta del fragmento con mayor confianza y una puntuación promediada, evitando que un concepto de varias palabras se registre como entidades sueltas.

Normalización: mapeo de entidades a *SNOMED CT* y *CIE-10-ES*

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

TÉRMINO	SNOMED CT	CIE-10-ES
hernia discal	84857004	- (no aplica)
fentanilo	373492002	T40.4 / X42 / X62 / Y12 / Y45.0
doloroso	31681005 Valor incorrecto	R20.0

Durogesic, 50 µg/h y cuadro doloroso no tienen código clínico esperado (marca comercial, dosis y síntoma inespecífico) y quedan fuera del cálculo de aciertos.

El informe *LLM*: acierta el relato, arrastra errores previos

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

INFORME

Mujer de 53 años, **hernia discal**:
Durogesic → fentanilo genérico
(empeora) → vuelve a Durogesic
(mejora).

Impresión diagnóstica

Hernia Discal a estudio

OBSERVACIONES DE LA AUDITORÍA

ASR: casi perfecto (duplica "Durogesic Durogesic").

NER: "analgesia" = falso positivo (PROBLEM).

SNOMED: "doloroso" → *Trigeminal neuralgia* (CIE-10 err.).

Informe: dosis $\times 1000$ ("50 $\mu\text{g}/\text{h}$ " → "50 mg/hora").

El *Bundle FHIR* del caso: válido en forma, no en contenido

1 · Captura

2 · ASR

3 · NER

4 · Normaliz.

5 · Generación

6 · Validación

VALIDACIÓN ESTRUCTURAL

FHIR válido

El *JSON FHIR* de este caso supera la validación estructural: `resourceType`, referencias `subject` y `meta.profile` correctos.

ADVERTENCIA SEMÁNTICA

La validación **no filtra** el contenido: el *Bundle* traslada, sin corregirlos, los errores ya vistos en este mismo caso.

Terminología: "*doloroso*" → *Trigeminal neuralgia* codificado como hallazgo (*CIE-10* err.).

Informe: dosis $\times 1000$ ("*50 mg/hora*") pasa intacta al `MedicationStatement`.

Evaluación por módulos y de extremo a extremo

10

casos de referencia

Muestreo aleatorio de SPACCC (1.000 casos); *gold standard* anotado con Claude Opus 4.5.

Evaluación por módulos

ASR · NER · Terminología

Cada etapa, aislada, frente a su propio *gold standard* (WER, precisión, *recall*, *F1*).

LLM-as-judge

Evaluación *end-to-end*

Puntúa 1–5 en 5 dimensiones y emite veredicto de aceptación clínica (*proxy* del Objetivo 3).


Los tres artefactos de salida (Reporte.txt, Informe.txt, Fhir_Reporte.json) se contrastan contra el texto de referencia de cada caso, en local y sin GPU de servidor.

14 · RESULTADOS *END-TO-END*

14 / 18

***Streaming* puntúa más en las 5 dimensiones, pero cuesta $\approx 6\times$ más tiempo**

● *Streaming*
● *Batch*



5 / 5

Dimensiones donde
streaming supera a *batch*

$\approx 6\times$

Más tiempo: 184.9 s vs
30.6 s de media

FHIR

Dimensión mejor puntuada
en ambos modos

15 · HALLAZGO CENTRAL

Los errores no se diluyen en el *pipeline*: se acumulan

MÓDULO	EVALUACIÓN AISLADA		END-TO-END (1–5)
ASR	≈6.5 % (WER)	→	3.75–4.0 / 5
NER	32.0–43.8 % (F1)	→	2.10–2.90 / 5
Terminología	85.5 % (SNOMED)	→	1.55–1.90 / 5

Cada etapa consume la salida de la anterior sin posibilidad de corrección aguas abajo: un error moderado en origen (una sigla mal transcrita, una entidad truncada) se compone con el siguiente y se amplifica hasta convertirse en un error clínico grave en el informe final.

20–30 %

de los informes completos
resultan aceptables
(*LLM-as-judge*)

Cumplimiento dispar entre objetivos técnicos y clínicos

	OBJETIVO 1 · ASR $WER \leq 10-12\%$	RESULTADO $\approx 6.5\%$ medio	Consistente en ambas modalidades y los 10 casos; rango bajo ($\approx 0.6-13.6\%$).
	OBJETIVO 2 · NER $F1 \geq 0.85$	RESULTADO $32.0-43.8\%$	Muy por debajo del umbral: sobre-segmentación de <i>spans</i> y siglas/abreviaturas no reconocidas.
	OBJETIVO 3 · CLÍNICA $\geq 80\%$ aceptación	RESULTADO $20\% \cdot 30\%$	Propagación y amplificación de errores entre etapas del <i>pipeline</i> secuencial.
	OBJETIVO 4 · FHIR $FHIR > 95\%$ válido	RESULTADO 100%	Válido no es lo mismo que correcto: hereda sin filtrar los errores semánticos previos.

■ Cumplido ■ Cumplido con reservas ■ No cumplido

17 · CONCLUSIONES



El desempeño de un sistema clínico de este tipo no puede inferirse a partir del desempeño aislado de sus componentes.

Conclusiones generales · Capítulo 7

1

Arquitectura completa y funcional

Cubre de extremo a extremo el flujo del audio al recurso *FHIR*. Cumple el Objetivo 1 (*WER*) y el Objetivo 4 con reservas.

2

El problema es la propagación, no los módulos

Errores moderados y aislados se amplifican al encadenarse sin corrección. Los Objetivos 2 y 3 no se cumplen por esta causa.

3

Prueba de concepto, no producto clínico

Técnicamente viable, pero sin el nivel de fiabilidad necesario para operar sin supervisión clínica humana.

Gracias

Preguntas y discusión

AUTOR

Eduardo Enrique Suárez Castro

eduardosuarez.c97@gmail.com

DIRECTOR

Francisco Javier Melero Rus